

1. 회귀(Regression)

1) 정의

- 독립변수(X)와 종속변수(Y) 간의 관계를 모델링하는 기법
- 목표: 최적의 회귀계수 (W)를 학습하여 Y 예측

2) 기본 모델

- ($Y = W_0 + W_1X_1 + \dots + W_nX_n$)

3) 핵심 개념

- 비용함수: RSS (Residual Sum of Squares)
- 목표: RSS 최소화

4) 장점

- 해석이 쉬움 (계수 기반)
- 빠르고 기본적인 모델

5) 단점

- 선형 관계 가정 필요
- 이상치 및 다중공선성에 취약

선형 회귀의 종류

- 일반 Linear Regression: 규제 적용하지 않은 모델, RSS 최소화를 위해 회귀 계수를 최적화
- Ridge Regression: 선형 회귀에 L2 규제 추가한 모델
- Lasso Regression: 선형 회귀에 L1 규제 추가한 모델
- ElasticNet Regression: L1, L2 규제를 함께 결합한 모델
- Logistic Regression: 이름은 회귀지만 분류에 사용되는 선형 모델

최적의 회귀 모델을 만든다는 것은

전체 데이터의 잔차(오류 값) 합이 최소가 되는 모델을 만드는 것!

동시에 오류 값 합이 최소가 될 수 있는 최적의 회귀 계수를 찾는다는 의미

2. 선형 회귀 모델 유형

2.1 OLS (일반 선형 회귀)

정의

- RSS 최소화 방식 (규제 없음)

장점

- 구현 간단
- 해석 용이

단점

- 과적합 발생 가능
- 다중공선성 문제 발생

2.2 Ridge (L2 규제)

정의

- 계수의 제곱을 패널티로 추가

특징

- 큰 계수를 줄임
- 모든 변수 유지

장점

- 다중공선성에 강함
- 모델 안정성 증가

단점

- 변수 선택 불가 (0으로 만들지 않음)

2.3 Lasso (L1 규제)

정의

- 계수의 절댓값을 패널티로 추가

특징

- 일부 계수를 0으로 만듦 (Feature Selection)

장점

- 자동 변수 선택 가능
- 모델 단순화

단점

- 상관 높은 변수 중 하나만 선택하는 경향

2.4 ElasticNet

정의

- $L1 + L2$ 혼합

장점

- 변수 선택 + 안정성 동시에 확보

단점

- 하이퍼파라미터 튜닝 필요

2.5 다항 회귀 (Polynomial Regression)

정의

- 입력 변수를 제곱, 세제곱 등으로 확장

특징

- 선형 모델이지만 비선형 관계 표현 가능

장점

- 복잡한 패턴 학습 가능

단점

- 차수 증가 시 과적합 위험

2.6 로지스틱 회귀

정의

- 시그모이드 함수 기반 분류 모델

특징

- 출력: 확률 $\rightarrow$ 분류

장점

- 확률 해석 가능
- 이진 분류에 강력

단점

- 복잡한 비선형 관계 한계

2.7 회귀 트리

정의

- 데이터를 분할하여 리프 노드 평균으로 예측

특징

- 계단형 함수

장점

- 비선형 관계 잘 반영
- 해석 직관적

단점

- 과적합 쉬움
- 데이터 변화에 민감

3. 주요 알고리즘

3.1 경사 하강법 (Gradient Descent)

정의

- 비용함수를 최소화하도록 파라미터 반복 업데이트

과정

1. 초기값 설정
2. 기울기 계산
3. 반대 방향으로 이동
4. 반복

종류

- Batch GD: 전체 데이터 사용 (정확, 느림)
- SGD: 일부 데이터 사용 (빠름, 불안정)
- Mini-batch: 절충

장점

- 대규모 데이터에 적합

단점

- 학습률 설정 민감
- 지역 최솟값 문제

3.2 편향-분산 트레이드오프

정의

- 모델 복잡도에 따른 오류 균형

상태 특징

High Bias 과소적합

High Variance 과적합

적절 최적 모델

4. 평가 지표

4.1 MAE

- 절대 오차 평균
- 이상치 영향 적음

4.2 MSE

- 제곱 오차 평균
- 큰 오차에 민감

4.3 RMSE

- MSE의 루트
- 해석 쉬움

4.4 MSLE

- 로그 기반 오차
- 성장 데이터에 적합

4.5 R^2

- 설명력 지표 (0~1)

5. 데이터 전처리 및 차원 축소

5.1 스케일링

방법

- StandardScaler: 평균 0, 분산 1
- MinMaxScaler: 0~1 범위

목적

- 모델 성능 향상
- 경사하강법 안정화

5.2 로그 변환

목적

- 왜곡된 분포 정규화
- 이상치 완화

5.3 차원 축소

목적

- 변수 수 감소
- 다중공선성 해결

예

- PCA

5. 전체 흐름

- 예제 풀이시 우리가 하는거

1. 데이터 전처리 (결측치, 스케일링)
2. 모델 선택
 - 단순: OLS
 - 과적합: Ridge/Lasso
 - 비선형: 다항 / 트리
3. 학습 (fit)
4. 예측 (predict)
5. 평가 (RMSE, R^2 등)
6. 튜닝 (alpha, degree 등)

요약

- 회귀 = "값 예측"
- 핵심 목표 = "RSS 최소화"
- 과적합 해결 = "규제 (L1, L2)"
- 비선형 해결 = "다항 / 트리"
- 성능 판단 = "RMSE, R^2 "
- 모델 선택 기준:
 - 단순/해석 → 선형
 - 변수 많음 → Lasso
 - 안정성 → Ridge
 - 복잡 패턴 → 트리