
머신러닝 실습 핵심 정리 (자전거 대여 & 주택 가격 예측)

1. 데이터 전처리 및 탐색 (EDA)

회귀 분석의 성능은 데이터의 분포와 질에 결정됩니다.

- **로그 변환 (Log Transformation):** 타깃값이나 피처의 왜곡도(Skewness)가 높을 때 `np.log1p()`를 적용하여 정규 분포 형태로 변환합니다.
- **결측치 처리:** `df.isna().sum()`으로 확인 후, `fillna()`를 통해 평균값이나 최빈값으로 보간합니다.
- **인코딩 (Encoding):** 카테고리형 피처는 `pd.get_dummies()`를 활용한 원-핫 인코딩으로 수치화합니다.
- **이상치(Outlier) 제거:** 산점도(Scatter Plot)를 통해 데이터 흐름에서 크게 벗어난 레코드를 찾아 `drop()`으로 삭제합니다.

2. 선형 회귀 모델 및 규제 (Regularization)

단순 선형 회귀의 과적합 문제를 해결하기 위해 규제가 포함된 모델을 사용합니다.

- **LinearRegression:** 가장 기본적인 선형 회귀 알고리즘입니다.
- **Ridge (L2 규제):** 회귀 계수의 제곱합에 패널티를 부여하여 계수 크기를 줄입니다.
- **Lasso (L1 규제):** 불필요한 피처의 회귀 계수를 0으로 만들어 피처 선택 효과를 냅니다.
- **하이퍼 파라미터 튜닝:** `GridSearchCV`를 활용해 최적의 규제 강도(alpha)를 탐색합니다.

3. 평가 지표 (Evaluation Metrics)

회귀 모델의 성능을 측정하기 위해 실제값과 예측값의 차이를 계산합니다.

- **MSE (Mean Squared Error):** 오차 제곱의 평균입니다.
- **RMSE (Root Mean Squared Error):** MSE에 루트를 씌워 실제 단위와 맞춘 지표입니다.
- **RMSLE (Root Mean Squared Log Error):** 로그 변환된 값의 차이를 계산하며, 결정값의 크기에 따른 왜곡을 방지합니다.

4. 앙상블 및 트리 기반 모델 (Ensemble)

복잡한 데이터 패턴을 학습하기 위해 여러 모델을 결합합니다.

- **XGBoost & LightGBM**: 강력한 성능을 가진 그래디언트 부스팅 트리 알고리즘입니다.
 - **num_leaves, n_estimators, learning_rate** 등의 파라미터로 성능을 조절합니다.
- **혼합 모델 (Blending)**: 서로 다른 모델(예: Ridge + Lasso)의 예측값에 가중치를 곱하여 합산합니다.
- **스태킹 (Stacking)**: 개별 모델들의 예측 결과물을 다시 학습 데이터로 삼아 메타 모델이 최종 예측을 수행하는 고차원 앙상블 기법입니다.

5. 주요 활용 함수 정리

실습에서 반복적으로 사용된 핵심 로직입니다.

- **get_rmse(models)**: 여러 모델의 RMSE를 한꺼번에 계산 및 반환.
 - **get_top_bottom_coef(model)**: 회귀 계수가 큰 상위/하위 피처를 추출하여 영향력 파악.
 - **visualize_coefficient(models)**: 모델별 피처 중요도를 시각화하여 비교.
 - **get_stacking_base_datasets()**: 스태킹 모델 학습을 위한 교차 검증 기반 데이터 생성.
-