
비지도학습 군집화 & RFM 분석

1. 군집화 알고리즘 비교

1-1. K-Means

- 가장 직관적인 거리 기반 군집화 알고리즘
- 중심점(Centroid)을 반복적으로 업데이트하며 군집 형성
- 원형 구조(make_circles)나 타원형 데이터 분포에서는 한계 존재
- 거리 기반 분할 특성상 복잡한 형태의 데이터 분리에 취약

1-2. GMM (Gaussian Mixture Model)

- 여러 개의 가우시안 분포가 혼합된 구조라고 가정하는 확률 기반 모델
- K-Means보다 군집 모양을 유연하게 표현 가능
- 타원형 분포 등 복잡한 데이터에도 효과적

1-3. DBSCAN (Density-Based Spatial Clustering)

- 밀도 기반 군집화 알고리즘
- eps 반경 내 최소 데이터 개수(min_samples)를 기준으로 군집 형성
- 복잡한 기하학적 구조 탐지에 강점
- 군집에 속하지 않는 데이터는 노이즈(-1)로 분류 가능

2. 고객 세그멘테이션 및 RFM 분석

2-1. 온라인 리테일 데이터 전처리

- Quantity(주문 수량) ≤ 0 제거
- UnitPrice(상품 단가) ≤ 0 제거
- CustomerID 결측치 제거
- 이상 데이터 제거를 통해 분석 왜곡 방지

2-2. RFM 지표 정의

Recency (최근성)

- 특정 기준일 기준으로 최근 주문 이후 경과 일수 계산
- 예: 2011년 12월 10일 기준

Frequency (구매 빈도)

- 고객별 총 주문 건수 계산
- InvoiceNo 개수 기준 집계

Monetary (구매 금액)

- $\text{Quantity} \times \text{UnitPrice}$ 로 계산한 sale_amount 사용
- 고객별 총 구매 금액 합산

2-3. 데이터 왜곡 해소 (로그 변환)

- 소수 고객의 대량 구매로 인해 데이터 치우침(Skewness) 발생
- K-Means 적용 전 로그 변환 필요
- $\text{np.log1p}()$ 적용 후 StandardScaler로 표준화 수행

3. 평가 지표 및 차원 축소

3-1. 실루엣 스코어 (Silhouette Score)

- 군집 내부 응집도와 군집 간 분리도를 측정하는 지표
- 값이 클수록 군집화 품질이 좋음
- 군집별 실루엣 계수 분포를 시각화하여 최적 K 탐색 가능

3-2. PCA (주성분 분석)

- 고차원 데이터를 저차원으로 축소하는 기법
- 붓꽃 데이터(4차원)를 2차원으로 시각화할 때 활용
- $\text{n_components}=2$ 설정 후 ftr1, ftr2 좌표 생성

4. 주요 활용 함수 정리

4-1.

```
visualize_cluster_plot(  
    model,  
    cluster_data,  
    cluster_col_name,  
    feature_names_to_plot,  
    iscenter=True  
)
```

기능:

- K-Means, GMM, DBSCAN 결과를 2차원 산점도로 시각화
- 모델 종류에 따라 중심점(Centroid) 표시 가능
- DBSCAN 노이즈 포인트(-1) 처리 가능

4-2.

```
visualize_silhouette_coeff(  
    [2, 3, 4, 5],  
    X_features_scaled  
)
```

기능:

- 군집 개수(K)별 실루엣 계수 시각화
 - 최적 군집 수 탐색 지원
 - 군집별 데이터 분포 상태 확인 가능
-