Week2

2장 사이킷런으로 시작하는 머신러닝

사이킷런 소개와 특징

1. 사이킷런
    a. 파이썬 머신러닝 라이브러리 중 가장 많이 사용되는 라이브러리
    b. 파이썬 기반의 머신러닝은 곧 사이킷런으로 개발하는 것을 의미할 정도
    c. 파이썬 기반의 다른 머신러닝 패키지도 사이킷런 스타일의 API를 지향할 정도로 쉽고 가장 파이썬스러운 API를 제공
    d. 머신러닝을 위한 매우 다양한 알고리즘과 개발을 위한 편리한 프레임워크와 API를 제공
    e. 오랜 시간 실전 환경에서 검증됐으며, 매우 많은 환경에서 사용되는 성숙한 라이브러리

첫 번째 머신러닝 만들어 보기 - 붓꽃 품종 예측하기

sklearn.tree : 의사결정트리 같은 트리 기반 머신러닝 알고리즘

sklearn.model_selection : 데이터 분할과 하이퍼파라미터 튜닝을 위한 모듈

학습데이터와 테스트 데이터로 분리 → train_test_split()

feacture 데이터 셋 : 설명변수들 x

label 데이터 셋 : 예측하려는 정답 값 y

의사결정트리(decision tree) : 데이터를 질문으로 계속 나누면서 분류 및 예측

1. 데이터 세트 분리
2. 모델 학습(의사결정트리 형성)
3. 예측
4. 평가

사이킷런의 기반 프레임워크 익히기

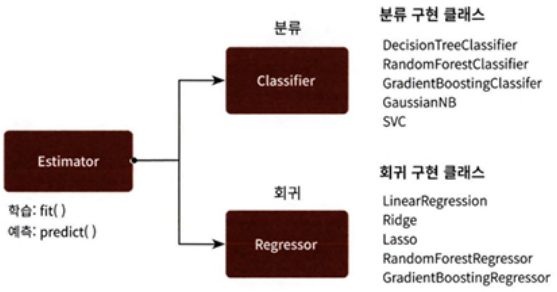

model selection 모듈 소개

1. 학습/테스트 데이터 세트 분리 train_test_split()
2. 교차 검증 - k 폴드 교차 검증

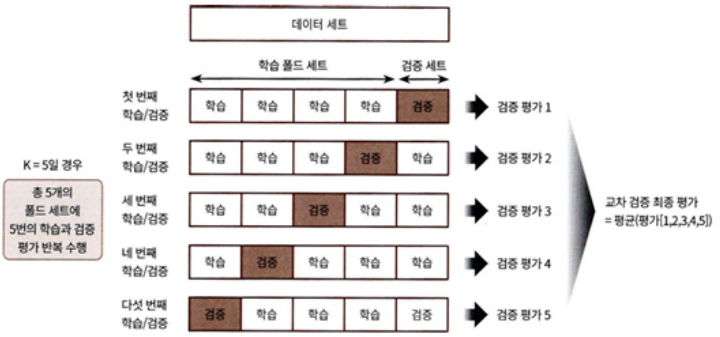

3. stratified k 폴드
    a. 불균형한 분포도를 가진 레이블 데이터 집합을 위한 k 폴드 방식
4. 교차 검증을 보다 간편하게 - cross_val_score()
5. GridSearchCV - 교차 검증과 최적 하이퍼 파라미터 튜닝을 한 번에

데이터 전처리

레이블 인코딩 : LableEncoder

각각의 라벨에 번호를 부여하는 방식

가중치가 부과될 수 있음.

원-핫 인코딩: OneHotEncoder

새로운 열을 만들고 포함 여부에 따라 0, 1로 나눔

원핫은 문자열을 숫자형으로 변환해야 하지만 pd.get_dummies()를 이용하면 바로 변환할 수 있음.

피처 스케일링과 정규화

표준화

$$x_i_new = \frac{x_i - mean(x)}{stdev(x)}$$

정규화

$$x_i_new = \frac{x_i - \min(x)}{\max(x) - \min(x)}$$

MinMaxScaler

데이터 값을 0~1 사이로 변환, 데이터 분포가 가우시안 분포가 아닐 경우에 적용함

학습 데이터와 테스트 데이터의 스케일링 변환 시 유의점

1. 학습데이터: fit() → transform() or fit_transform()
2. 테스트 데이터: 절대 fit(() 안됨, 오직 transform()만 사용
3. 이유: 학습 데이터 기준으로 테스트 데이터를 변환해야 모델 예측이 일관됨

3장 평가

1. 정확도

$$\text{정확도(Accuracy)} = \frac{\text{예측 결과가 동일한 데이터 건수}}{\text{전체 예측 데이터 건수}}$$

2. 오차행렬

		예측 클래스 (Predicted Class)	
		Negative(0)	Positive(1)
실제 클래스 (Actual Class)	Negative(0)	**TN** (True Negative)	**FP** (False Positive)
	Positive(1)	**FN** (False Negative)	**TP** (True Positive)

3. 정밀도와 재현율

정밀도 = TP / (FP + TP)

재현율 = TP / (FN + TP)

4. 정밀도와 재현율의 트레이드오프
    a. 정밀도와 재현율은 상호 보완적인 평가 지표이기에, 한 쪽이 올라가면 한 쪽은 내려가는 트레이드오프가 발생
5. F1 스코어

$$F1 = \frac{2}{\frac{1}{recall} + \frac{1}{precision}} = 2 * \frac{precision * recall}{precision + recall}$$

6. ROC 곡선과 AUC

FPR = FP / (FP + TN) = 1 - TNR = 1- 특이성