[Ch.2 사이킷런으로 시작하는 머신러닝]

Scikit-learn(사이킷런): 파이썬에서 가장 대표적인 머신러닝 라이브러리

• 대부분의 알고리즘이 동일한 API 구조를 사용:

fit() → 모델 학습, predict() → 예측 수행.

• 지도학습(Supervised Learning): Feature(입력데이터)와 Label(정답 데이터)을 이용해 모델을 학습

대표 예시: 붓꽃(Iris) 데이터셋 분류 문제.

머신러닝 기본 프로세스

Fit() – ML 모델 학습 [지도 학습]

입력 데이터 형태에 맞춰 데이터 변환을 위한 사전작업 [비지도학습]

(+) transform() : 차원변환, 클러스터링, 피처 추출 => fit_transform

predict – 학습된 모델의 예측

- 모델 학습: model.fit(X_train, y_train)
- 예측 수행: model.predict(X_test)

주요 모듈

datasets: 예제 데이터 제공	model_selection: 데이터 분리, 교차 검증	preprocessing: 데이터 전처리	metrics: 모델 평가 지표	tree, svm, neighbors 등: 머신러닝 알고리즘

Model Selection

• train_test_split(): 학습 데이터와 테스트 데이터를 분리

Test_size	테스트 데이터 세트 크기 얼마	Default =1/4
Train_size	학습용 데이터 세트 크기 얼마	Default=X
Shuffle	데이터 분리 전 섞을 지 결정	Default= True
Random_state	호출시 동일 분리 세트 생성을 위한 난수값	

- K-Fold Cross Validation: 데이터를 K개로 나누어 반복 학습 및 평가
- Stratified K-Fold: 레이블 비율을 유지하면서 교차검증 수행

  불균형한 분포도를 가진 레이블 데이터 집합을 위한 K 폴드
- cross_val_score(): 교차검증을 간단히 실행하는 함수

1. 폴드 세트 설정 2. for문으로 인덱스 추출 3. 반복 학습,예측 후 성능반환

cross_val_score(estimator, X, y=None, scoring=None, cv=None, n_jobs=1, verbose=0, fit_params=None, pre_dispatch='2*n_jobs') estimator: 사이킷런의 Classifier 또는 Regressor X: feature set y: label data set Scoring: 예측 성능 평가지표 cv: 교차검증폴드수

GridSearchCV : 모델의 최적 하이퍼 파라미터(머신러닝 알고리즘 구성요소로, 이 값의 조정으로 성능 변화)를 찾기 위한 방법

Estimator (어떤 모델을 사용)	classfier, regressor, pipleline이 사용될 수 있다
param_grid (하이퍼파라미터 후보 딕셔너리)	key + 리스트 값을 가지는 딕셔너리가 주어짐
scoring : 성능 평가지표	예) accuuacy, 직접 만든함수도가능
CV (Cross Validation – 교차검증)	교차검증을 위해 분할되는 학습/테스트세트의 개수
Refit (다시 최적 찾을까말까) - Default : true	True – 최적 파라미터로 전체 데이터 재학습시킴 False – 성능평가는 하지만 최종학습된 모델은 없음

데이터 전처리

- 결측값 처리 (NaN, Null)
- 문자 데이터를 숫자로 변환해야 사용 가능 = "데이터 인코딩"
- Label Encoding: 문자 → 숫자 변환
- One-Hot Encoding: 범주형 데이터를 여러 컬럼으로 분리하여 표현

Feature Scaling : 서로 다른 피처(변수)의 값 범위를 일정 수준으로 조정

- StandardScaler: 평균 0, 분산 1로 표준화

Fit(), transform()을 쓰고, dataframe으로 변환

- MinMaxScaler: 값을 0~1 범위로 변환

Min, max를 0과 1로 지정해 나머지를 비율로

스케일링 규칙: train 데이터로 fit 후 test 데이터는 transform만 수행

[Ch.3 모델 평가]

머신러닝 모델의 성능을 평가하기 위한 지표 사용

Accuracy

- 정확도 = (맞춘 데이터 수) / (전체 데이터 수)
- 불균형 데이터에서는 성능이 왜곡될 수 있음 [이진 분류 경우, #2에서]

  성능 평가 지표 -> 이진 분류 , 멀티 분류

타이타닉 생존자 예측–Sex가 1이면 0, 0이면 1로 예측

MNIST 데이터 중 7 찾기- 모든 데이터를 0으로 예측

Confusion Matrix(오차 행렬)

TP: True Positive
TN: True Negative
FP: False Positive
FN: False Negative

Precision & Recall

- Precision = TP / (TP + FP) < - FP 감소에 집중
- Recall = TP / (TP + FN) < - FN 감소에 집중

F1 Score

- Precision과 Recall의 조화 평균
- 두 지표가 균형을 이룰 때 높은 값을 가짐

ROC Curve & AUC

- ROC Curve: FPR 대비 TPR 변화를 나타내는 곡선
- AUC: ROC 곡선 아래 면적
- AUC 값이 1에 가까울수록 좋은 모델