Week3_예습과제_명재서

4장 분류

4.1 분류(classifiacation)의 개요

- 지도학습의 대표적 유형
- 기존 데이터가 어떤 레이블에 속하는지 패턴을 알고리즘으로 인지한 뒤에 새롭게 관측된 데이터에 대한 레이블을 판별하는 것

분류를 구현하는 다양한 머신러닝 알고리즘 - 베이즈, 로지스틱 회귀, 결정 트리, 서포트 벡터 머신, 최소 근접 알고리즘, 앙상블

앙상블이란 ? - 서로 다른 / 같은 알고리즘을 결합한 형태

* 정형 데이터의 예측 분석 영역에서는 매우 높은 예측 성능으로 인해 많은 분석가와 데이터 과학자들에게 애용되고 있음.

- 배깅 방식 : 랜덤포레스트 - 뛰어난 예측 성능, 상대적으로 빠른 수행 시간, 유연성
- 부스팅 방식 : 그래디언트 부스팅, XgBoost, Light GBM 등

- 일반적으로 결정 트리를 기본 알고리즘으로 사용함.

4.2 결정 트리

결정 트리? - 데이터에 있는 규칙을 학습을 통해 자동으로 찾아내 트리 기반의 분류 규칙을 만드는 것.

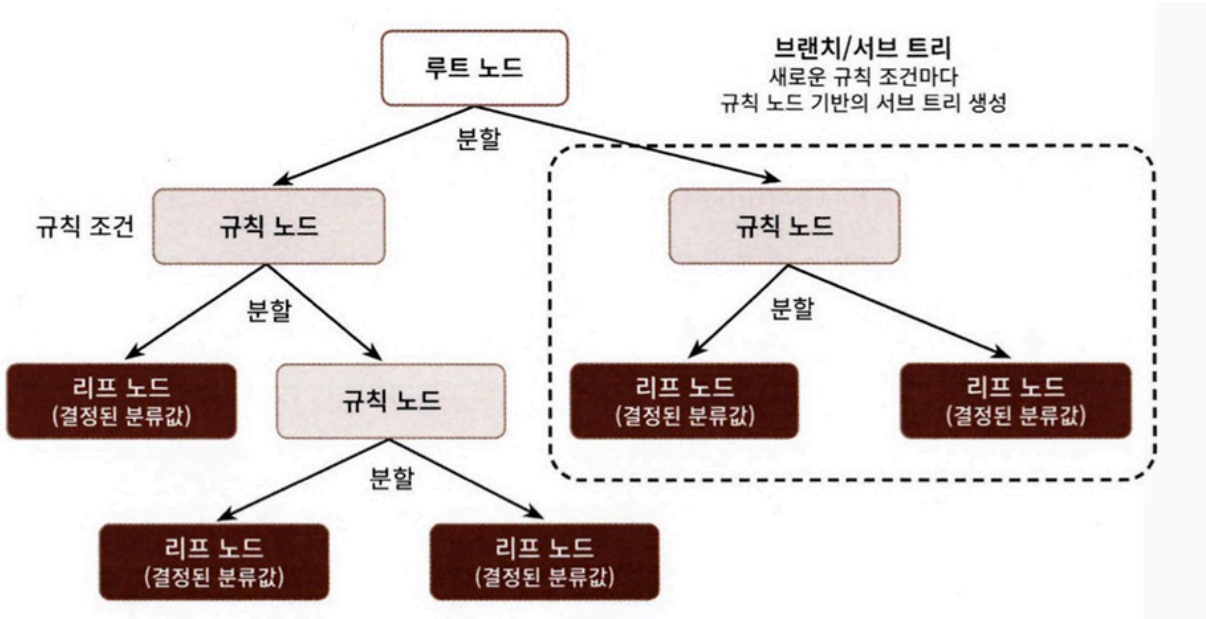

- 데이터의 어떤 기준을 바탕으로 규칙을 만들어야 가장 효율적인 분류가 될 것인가가 알고리즘의 성능을 크게 좌우함. → 가능한 한 적은 결정 노드로 높은 예측 정확도를 가지려면 데이터를 분류할 때 최대한 많은 데이터 세트가 해당 분류에 속할 수 있도록 결정 노드의 규칙을 정해야 함.
- 균일한 데이터 세트 구성이 중요! - 데이터를 구분하는 데 필요한 정보의 양에 영향을 미침.

정보의 균일도를 어떻게 측정? - 엔트로피를 이용한 정보 이득 계수와 지니 계수

정보 이득 지수 = 1 - 엔트로피 지수 (주어진 데이터의 혼잡도) → 이걸로 분할 기준을 결정함.

지니 계수 = 불평등 지수를 나타내는 계수. 0~1의 값을 가짐. 작을수록 데이터 균일도가 높은 것.

위에서 말한 두 조건을 찾아서 반복적으로 데이터를 분할하다가 데이터가 모두 특정 분류에 속하면 분류를 결정함.

[결정 트리 모델의 특징]

(1) 균일도라는 룰을 기반으로 하고 있어 알고리즘이 쉽고 직관적.

(2) 정보의 균일도만 신경 쓰면 ok. 전처리 작업 (스케일링 & 정규화)이 필요 없음.

(3) 과적합으로 인해 정확도가 떨어짐.

[결정 트리 파라미터]

1. min_samples_split : 노트 분할을 위한 최소 샘플 데이터 수로 과적합을 제어. 작게 설정할수록 과적합 위험 증가
2. min_samples_leaf : 분할될 경우 각 브랜치 노드에서 가져할 할 최소한의 샘플 데이터 수. 클수록 노트 분할을 상대적으로 덜 함. 과적합 제어 용도.
3. max_features : 최적의 분할을 위한 최대 피처 개수.
4. max_depth : 트리의 최대 깊이를 규정함.
5. max_leaf_nodes : 말단 노드의 최대 개수.

[결정 트리 모델의 시각화]

Graphviz : 결정 트리 알고리즘이 어떤 규칙을 가지고 트리를 생성하는지 시각적으로 보여줄 수 있는 방법.

export_graphviz() : 학습이 완료된 Estimator, 피처의 이름 리스트, 레이블 이름 리스트를 함수 인자로 입력하면, 학습된 결정 트리 규칙을 실제 트리 형태로 시각화해서 보여줌.

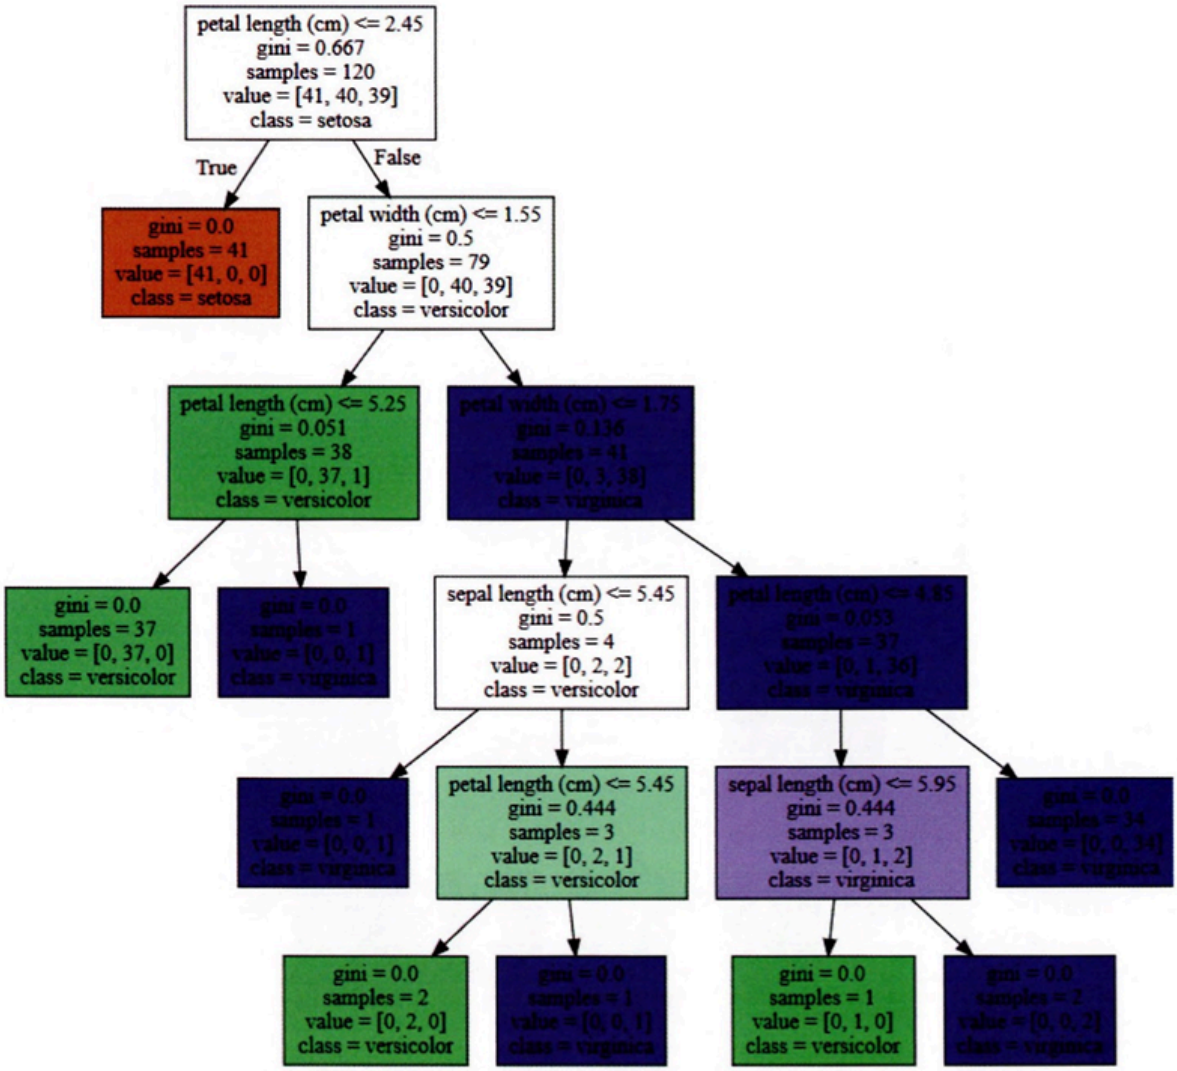

리프 노드 : 더 이상 자식 노드가 없음. 최종 클래스(레이블) 값이 결정되는 노드. (사진에서 맨 아래)

- 오직 하나의 클래스 값으로 최종 데이터 구성 or 하이퍼 파라미터 조건을 충족.

브랜치 노드 : 자식 노드가 있음. 자식 노드를 만들기 위한 분할 규칙 조건을 가지고 있음.

결정 트리 알고리즘이 학습을 통햐 규칙을 정하는 데 있어 피처의 중요하나 역할 지표를 DecisionTreeClassifier 객체의 feature_importances_속성으로 제공함.

feature_importances : 트리 분할 시 정보 이득이나 지니 계수를 얼마나 효율적으로 잘 개선시켰는지를 정규화된 값으로 표현한 것. 일반적으로 값이 높을수록 해당 피처의 중요도가 높다는 것을 나타냄.