

# 5장 회귀

## 5장 회귀

평균으로 회귀하려는 경향, 최적의 회귀 계수를 찾아내고자 함

회귀는 분류와 회귀로 나뉨


대표적인 선형 회귀 모델

- 일반 선형 회귀
- 릿지
- 라쏘
- 엘라스틱넷
- 로지스틱 회귀

## 02 단순 선형 회귀를 통한 회귀 이해

단순 선형 회귀 : 독립/종속변수 모두 하나


최적의 회귀 모델을 만든다 = 최적의 회귀 모델을 만든다 (RSS)



$$RSS(w_0, w_1) = \frac{1}{N} \sum_{i=1}^N (y_i - (w_0 + w_1 * x_i))^2$$

(i는 1부터 학습 데이터의 총 건수 N까지)

## 03 경사 하강법 소개



점진적인 하강'이라는 의미처럼, 반복적인 계산을 통해 회귀 계수(W) 파라미터 값을 업데이트 하면서 **비용 함수(Cost Function)가 최소가 되는 지점**을 찾는 방식

$$\frac{\partial R(w)}{\partial w_1} = \frac{2}{N} \sum_{i=1}^N -x_i * (y_i - (w_0 + w_1 x_i)) = -\frac{2}{N} \sum_{i=1}^N x_i * (\text{실제값}_i - \text{예측값}_i)$$

$$\frac{\partial R(w)}{\partial w_0} = \frac{2}{N} \sum_{i=1}^N -(y_i - (w_0 + w_1 x_i)) = -\frac{2}{N} \sum_{i=1}^N (\text{실제값}_i - \text{예측값}_i)$$

학습률을 계속 찾아가며 비용 함수가 최소가 되는 값을 찾는 것



### 비용 함수?

실제값과 예측값의 차이를 제공하여 합한 RSS를 주로 사용하며, 이를 최소화하는 것이 머신러닝 회귀의 핵심

## 04 사이킷런 LinearRegression을 이용한 보스턴 주택 가격 예측

RSS를 최소화하여 OLS 추정 방식으로 구현한 클래스

회귀계수 W를 coef\_에 저장함

|         |                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                           |
|---------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 입력 파라미터 | <p><b>fit_intercept</b>: 불린 값으로, 디폴트는 True입니다. Intercept(절편) 값을 계산할 것인지 여부를 지정합니다. 만일 False로 지정하면 intercept가 사용되지 않고 0으로 지정됩니다.</p> <div style="display: flex; justify-content: space-around; align-items: center;"> <div style="text-align: center;"> <p>fit_intercept=True</p>  </div> <div style="text-align: center;"> <p>fit_intercept=False</p>  </div> </div> <p><b>normalize</b>: 불린 값으로 디폴트는 False입니다. fit_intercept가 False인 경우에는 이 파라미터가 무시됩니다. 만일 True이면 회귀를 수행하기 전에 입력 데이터 세트를 정규화합니다.</p> |
| 속성      | <p><b>coef_</b>: fit() 메서드를 수행했을 때 회귀 계수가 배열 형태로 저장하는 속성. Shape는 (Target 값 개수, 피쳐 개수).</p> <p><b>intercept_</b>: intercept 값</p>                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                          |

## 회귀 평가 지표

| 평가 지표 | 설명                                                                                             | 수식                                                           |
|-------|------------------------------------------------------------------------------------------------|--------------------------------------------------------------|
| MAE   | Mean Absolute Error(MAE)이며 실제 값과 예측값의 차이를 절댓값으로 변환해 평균한 것입니다.                                  | $MAE = \frac{1}{n} \sum_{i=1}^n  Y_i - \hat{Y}_i $           |
| MSE   | Mean Squared Error(MSE)이며 실제 값과 예측값의 차이를 제곱해 평균한 것입니다.                                         | $MSE = \frac{1}{n} \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$         |
| RMSE  | MSE 값은 오류의 제곱을 구하므로 실제 오류 평균보다 더 커지는 특성이 있으므로 MSE에 루트를 씌운 것이 RMSE(Root Mean Squared Error)입니다. | $RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (Y_i - \hat{Y}_i)^2}$ |
| $R^2$ | 분산 기반으로 예측 성능을 평가합니다. 실제 값의 분산 대비 예측값의 분산 비율을 지표로 하며, 1에 가까울수록 예측 정확도가 높습니다.                   | $R^2 = \frac{\text{예측값 Variance}}{\text{실제값 Variance}}$      |

+MSE, RMSE에 로그를 적용한 MSLE도 사용

사이킷런 및 GridSearchCV 평가 시 사용되는 scoring 파라미터의 적용 값

| 평가 방법 | 사이킷런 평가 지표 API                                                                                            | Scoring 함수 적용 값                            |
|-------|-----------------------------------------------------------------------------------------------------------|--------------------------------------------|
| MAE   | <code>metrics.mean_absolute_error</code>                                                                  | <code>'neg_mean_absolute_error'</code>     |
| MSE   | <code>metrics.mean_squared_error</code>                                                                   | <code>'neg_mean_squared_error'</code>      |
| RMSE  | <code>metrics.mean_squared_error</code> 를 그대로 사용하되<br><code>squared</code> 파라미터를 <code>False</code> 로 설정. | <code>'neg_root_mean_squared_error'</code> |
| MSLE  | <code>metrics.mean_squared_log_error</code>                                                               | <code>'neg_mean_squared_log_error'</code>  |
| $R^2$ | <code>metrics.r2_score</code>                                                                             | <code>'r2'</code>                          |


## 05 다항 회귀와 과대적합/과소적합 이해

다항 회귀(Polynomial Regression): 독립변수의 차수를 높여 곡선 형태의 복잡한 관계를 모델링.

과적합(Overfitting) 문제: 차수가 지나치게 높아지면 '고분산' 상태가 되어 새로운 데이터에 대한 예측력이 급격히 하락.

트레이드오프:

- 고편향(High Bias): 모델이 너무 단순하여 오차가 큰 상태(과소적합).
- 고분산(High Variance): 모델이 학습 데이터 노이즈까지 학습한 상태(과적합).
- 결론: 둘의 합인 전체 오류가 최소화되는 지점을 찾는 것이 목표.



〈 편향과 분산에 따른 전체 오류 값(Total Error) 곡선, <http://scott.fortmann-roe.com/docs/BiasVariance.html>에서 발췌. 〉

## 06 규제 선형 모델 - 릿지, 라쏘, 엘라스틱넷

- 과적합(Overfitting) 발생:

RSS 최소화에만 집착 시 회귀 계수가 거대해짐 → 학습 데이터에만 과하게 최적화됨.

- 해결책: 비용 함수에 회귀 계수 크기 제어용 **페널티(Penalty)** 항 추가.

- 핵심: '학습 데이터 적합' vs '계수 크기 제어' 사이의 균형(Trade-off).



$$\text{비용 함수 목표} = \text{Min}(\text{RSS}(W) + \alpha * \|W\|_2^2)$$

| 모델명        | 규제 방식   | 핵심 특징 (음슴체)                                                                                                                                                                         |                                                                                                                                                                                                                                      |
|------------|---------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 릿지 (Ridge) | L2 규제   | <ul style="list-style-type: none"> <li>- 회귀 계수 제곱의 합에 페널티 부과.</li> <li>- 계수 크기를 전체적으로 축소함.</li> <li>- 계수를 0으로 만들지는 않음.</li> <li>- 다중공선성(피처 간 상관관계 높음) 방어에 유리함.</li> </ul>           | <p>"다 같이 조금씩 줄이자"</p> <ul style="list-style-type: none"> <li>• 중요도가 낮은 피처의 계수도 0에 아주 가깝게는 만들지만, 완전히 0으로 없애지는 않음.</li> <li>• 피처들끼리 서로 비슷비슷할 때(다중공선성), 어느 하나만 편애하지 않고 골고루 비중을 조절해서 예측을 안정적으로 만듦.</li> </ul>                            |
| 라쏘 (Lasso) | L1 규제   | <ul style="list-style-type: none"> <li>- 회귀 계수 절댓값의 합에 페널티 부과.</li> <li>- 불필요한 피처의 계수를 완전히 0으로 만듦.</li> <li>- 자동으로 피처 선택 (Feature Selection) 수행.</li> <li>- 모델 해석력이 높아짐.</li> </ul> | <p>"쓸데없는 건 다 버려"</p> <ul style="list-style-type: none"> <li>• 중요도가 낮은 피처의 계수를 진짜 0으로 만들어버림. (모델에서 삭제됨)</li> <li>• 피처 선택 (Feature Selection) 효과: 수많은 데이터 중 진짜 중요한 게 뭔지 골라내주니까 "아, 이 모델은 이 피처들 때문에 이런 결과가 나왔구나"라고 해석하기 쉬워짐.</li> </ul> |
| 엘라스틱넷      | L1 + L2 | <ul style="list-style-type: none"> <li>- L1과 L2 규제를 결합한 방식.</li> <li>- 라쏘의 단점(상관관계 높은 피처 중 하나만 선택) 보완.</li> <li>- 계수 변화의 안정성 확보 가능.</li> <li>- 학습 시간이 상대적으로 오래 걸림.</li> </ul>       | <p>"둘이 섞어서 단점 보완해"</p> <ul style="list-style-type: none"> <li>• 불필요한 피처는 0으로 만들면서도 (라쏘), 상관관계가 높은 피처들 사이에서는 계수값이 급격히 변하지 않게 잡아줌(릿지).</li> <li>• 단점: 두 가지 벌칙을 다 계산해야 하니 컴퓨터가 일하는 시간(학습 시간)이 제일 오래 걸림.💡 한 줄 요약</li> </ul>              |


## 핵심 파라미터: 알파 (α)

- α 값의 역할: 규제의 강도를 조절하는 하이퍼 파라미터.

- $a = 0$ : 규제 없음. 일반 선형 회귀(OLS)와 동일.
  - $a$  증가: 규제 강해짐 → 회귀 계수 작아짐 → 분산 감소, 편향 증가 (과적합 방지).
  - $a$  감소: 규제 약해짐 → 회귀 계수 커짐 → 분산 증가, 편향 감소 (학습 데이터 최적화).
- \*규제가 커진다 = 훈련 데이터에만 너무 집착하지 못하도록 벌칙을 더 세게 준다.

## 07 로지스틱 회귀

: 이름은 회귀지만 실제로는 분류



〈로지스틱 회귀의 시그모이드 함수〉

시그모이드 함수의  $y$  범위가 0~1인 걸 활용하여  $0 \sim 1$ 에 속할 확률을 표현한 것.  
시그모이드 함수 반환 값을 확률로 간주해, 확률에 따라 분류를 결정한다는 것이다.

로지스틱 회귀의 규제 (Regularization)

로지스틱 회귀도 과적합을 막기 위해 릿지(L2)나 라쏘(L1) 규제를 적용할 수 있음.

- 사이킷런에서는  $C$ 라는 파라미터로 규제 강도를 조절함.
- 선형 회귀의  $a$ 와는 반대 개념임.
  - $C$ 가 커지면: 규제가 약해짐 (학습 데이터에 더 집착).
  - $C$ 가 작아지면: 규제가 강해짐 (모델이 더 단순해짐).

## 08 회귀 트리


: 회귀 함수를 기반으로 하는 게 아니라, **결정 트리(Decision Tree)** 알고리즘을 회귀에 적용한 모델

차이점 :

- **선형 회귀**: 가중치( $w$ ) 조합으로 최적의 직선(회귀 계수)을 찾음.
- **회귀 트리**: 데이터를 여러 개의 구간(노드)으로 나누고, 각 구간 내 데이터의 **평균값**을 예측값으로 함.

### 작동 원리

1. **데이터 분할**: 피쳐 조건에 따라 데이터를 하위 노드로 계속 나눔 (트리 구조).
2. **예측값 결정**: 리프 노드(더 이상 안 나뉘지는 마지막 칸)에 속한 데이터들의 **평균**이 해당 구간의 최종 예측값이 됨.
3. **예측 방식**: 새로운 데이터가 들어오면 트리 규칙에 따라 특정 리프 노드로 보내고, 그 노드의 평균값을 정답으로 내놓음.



(( $x$ 값의 범위에 따라 평균을 따로 잡아서 데이터를 나누고 각각의 범위에서 결정트리를 한 다음에 한번에 모으는 구조))



## 주요 특징 및 알고리즘

- **비선형성 처리:** 직선으로 표현하기 힘든 복잡한 곡선 형태의 데이터도 유연하게 잘 예측함.
- **알고리즘 종류:**
  - **CART:** 분류뿐만 아니라 회귀도 가능한 가장 기본적인 트리 알고리즘.
  - **앙상블 기반:** 랜덤 포레스트(Random Forest), GBM, XGBoost, LightGBM 등 강력한 성능을 내는 모델들이 모두 회귀 트리 모드를 지원함.

## 선형 회귀 vs 회귀 트리 시각화 차이

- **선형 회귀:** 데이터 전체를 관통하는 부드러운 직선 또는 곡선 형태.
- **회귀 트리:** 구간별로 예측값이 계단처럼 끊어지는 **계단형(Step)** 형태.