

week10 예습과제

≡ 다중 선택

week10


Ch6. 차원 축소(Dimension Reduction)

01 차원 축소의 개요

- 차원이 많을 때의 문제점
 - **sparse 한 구조** : 차원 증가 → 데이터 포인트 간의 거리 기하급수적 증가 → 회소 (sparse)한 구조 가짐
 - **신뢰도 ↓** : 피처가 과하게 많으면 적은 차원에서 학습된 모델보다 신뢰 ↓
 - **다중 공산성 문제** 발생 가능성 ↑ : 피처가 많을 수록 상관관계가 높은 피처가 있을 가능성 ↑
 - **직관적인 데이터 해석 어렵** (↔ 3차원 이하의 차원 축소를 하면 시각적 데이터 표현 가능)
 - 필요한 **처리 능력 ↑**
- 종류
 - 피처 선택(feature selection) : 종속성이 강한 피처 제거
 - 피처 추출(feature extraction) : 기존 피처를 저차원의 중요 피처로 압축하여 추출
 - 기존 피처가 인지하기 어려웠 잠재적 요소(Latent Factor)를 추출
- 예시 : PCA, SVD, NMF
- 이미지나 텍스트에서의 활용
 - 이미지
 - 수많은 픽셀로 이루어진 이미지 데이터 잠재된 특성을 피처로 도출 → 함축적 형태의 이미지 변환과 압축 수행 ⇒ 과적합 영향 ↓
 - 텍스트
 - 텍스트 문서의 숨겨진 의미 추출

- 문서 내 단어들의 구성에서 숨겨진 시맨틱(Semantic) 의미나 토픽(Topic)을 잠재 요소로 간주하여 찾아냄
- SVD와 NMF가 시맨틱 토픽 모델링 기반 알고리즘으로 사

02 PCA(Principal Component Analysis)



- 기본 아이디어
 - 변수간의 상관관계를 이용하여 **주성분(Principal Component)**을 추출해 차원을 축소 + **정보 유실 최소화**가 목표
 ⇒ 가장 **높은 분산(=데이터의 변동성)**을 가지는 **데이터의 축(→ PCA의 주성분)**을 기준으로 데이터를 투영해 차원 축소
 - 주성분 구하기
 - 첫 번째 주성분 (PC1): 데이터가 가장 많이 퍼진 방향 (최대 분산)
 - 두 번째 주성분 (PC2): PC1과 직교하면서 그 다음으로 분산이 큰 방향
 - n+1 번째 주성분 (PCn+1): PCn와 직교하면서 그 다음으로 분산이 큰 방향
 ⇒ “벡터 축의 개수 = 차원”
 - 작은 주성분으로 원본 데이터의 총 변동성을 대부분 설명 가능
- 선형대수 관점
 - 핵심: **공분산 행렬**을 고유값 분해해서 **고유벡터를 새로운 축**으로 사용
 - Q1. 왜 공분산 행렬의 고유벡터를 새로운 축으로 하지?
 - 공분산 행렬은 모든 피쳐 간의 관계(분산+공분산)을 담은 전체 정보
 - 공분산 행렬을 고유값 분해하면 고유값은 **특정방향(고유 벡터)**을 기준으로 **공분산 행렬을 재해석했을 때의 분산의 크기**
 - 공분산행렬(Σ)의 고유값 분해
 : $\Sigma = Q \Lambda Q^T$


- Q: 고유벡터 행렬 (새 좌표축) → **직교 행렬**
 - Q2. 대칭 행렬은 항상 직교 고유벡터를 가지는데 왜지?
 - 대칭 행렬은 좌우 섞임이 없는 구조
($x \rightarrow y$ 로 밀어넣는 힘과 $y \rightarrow x$ 로 미는 힘의 방향 간 “비대칭 섞임”이 없음)
 - 따라서 서로 다른 고유값 방향들이 서로 간섭 $X \rightarrow$ 반드시 직교
- **Λ: 고유값을 모은 대각행렬** (각 축의 분산 크기)(고유값이 큰 순서대로 정렬되어 있음)
- PCA 구하는 스텝
 1. 입력 데이터 세트의 공분산 행렬을 생성
 2. 공분산 행렬의 고유벡터와 고유값을 계산
 3. 고유값이 가장 큰 순으로 K개(PCA 변환 차수만큼)만큼 고유벡터를 추출
 4. 고유값이 가장 큰 순으로 추출된 고유벡터를 이용해 새롭게 입력 데이터를 변환

03 LDA(Linear Discriminant Analysis)


(= 선형 판별 분석)

- PCA와의 차이점

PCA:
component axes that maximize the variance



LDA:
maximizing the component axes for class-separation



- 분류에서 사용하기 쉽도록 개별 클래스를 분별할 수 있는 기준을 최대한 유지하며 차원 축소 → **결정 값 클래스**를 최대한으로 분리할 수 있는 축 찾기
- 클래스의 결정 값이 필요하기 때문에 **지도학습**(↔ PCA는 비지도 학습)

- 클래스 간 분산(between-class scatter) 최대화 + 클래스 내부 분산(within-class scatter) 최소화
- LDA 구하는 스텝
 - 클래스 내부와 클래스 간 분산 행렬을 구함
(입력 데이터의 결정 값 클래스별로 개별 피처의 평균 벡터(mean vector)를 기반으로 구함)
 - 클래스 내부 분산 행렬을 S_W , 클래스 간 분산 행렬을 S_B 라고 하면 다음 식으로 두 행렬을 고유벡터로 분해 가능

$$S_W^T S_B = [e_1 \cdots e_n] \begin{bmatrix} \lambda_1 & \cdots & 0 \\ \cdots & \cdots & \cdots \\ 0 & \cdots & \lambda_n \end{bmatrix} \begin{bmatrix} e_1^T \\ \cdots \\ e_n^T \end{bmatrix}$$


- 고유값이 가장 큰 순으로 K개(LDA변환 차수만큼) 추출
- 고유값이 가장 큰 순으로 추출된 고유벡터를 이용해 새롭게 입력 데이터를 변환

04 SVD(Singular Value Decomposition)

(= 특이값 분해)

- PCA와의 차이점
 - 정방행렬이 아닌 행렬에도 적용 가능
- SVD 수식
 - 기본

$$A = U \Sigma V^T$$



- $\Sigma(m \times n)$: 대각행렬, 0이 아닌 값이 행렬 A(원본 데이터)의 특이값

- $U(m \times m)$, $V^T(n \times n)$: 이 행렬에 속한 벡터들이 특이 벡터 $\rightarrow$ 서로 직교
- 컴팩트한 형태(일반)

$$A_{m \times n} = U_{m \times m} \Sigma_{m \times n} V^T_{n \times n}$$


- 위의 Σ 의 비대각인 부분과 대각 원소 중에서도 특이 값이 0인 부분 제거 $\rightarrow$ 컴팩트한 형태로 SVD 적용
 $\Rightarrow U(m \times p)$, $\Sigma(p \times p)$, $V^T(p \times n)$
- Truncated SVD : Σ 의 대각원소 중에 상위 몇 개만 추출해서 여기에 대응하는 U 와 V 의 원소도 함께 제거해 더욱 차원을 줄인 형태로 분해

• PCA vs SVD

구분	PCA (주성분 분석)	SVD (특이값 분해)
분해 대상	공분산 행렬 ($X^T X$)	원본 데이터 행렬 (X)
수학적 원리	고유값 분해 (Eigen-Decomposition)	특이값 분해 (Singular Value Decomposition)
전제 조건	데이터의 평균을 0으로 맞추는 과정이 필수	평균화 과정 없이 원본 행렬에 바로 적용 가능

05 NMF(Non-Negative Matrix Factorization)

- 조건 : 원본 행렬의 모든 원소 값이 0 이상이라는게 보장
- 기본 아이디어 : 원본 행렬을 두 개의 기반 양수 행렬로 분해 ($\rightarrow$ 하나의 행렬을 두 개로 근사해 분해)
- 잠재 요소 도출



- 보통 길고 가는 행렬 W와 얇고 넓은 행렬 H로 분해
- W : 원본 행에 대해서 이 잠재요소의 값이 얼마나 되는지
- H : 이 잠재 요소가 원본 열(속성)로 어떻게 구성됐는지
- 활용 : 이미지 압축을 통한 패턴 인식, 텍스트 토픽 모델링, 문서 유사도 및 클러스터링, 추천 영