

< 군집화 >

1. K-평균(K-Means) 알고리즘 이해

- **정의:** 군집화에서 가장 일반적으로 사용되는 알고리즘으로, 임의의 군집 중심점(Centroid)을 선택해 해당 중심에 가장 가까운 포인트들을 선택하는 기법
- **동작 프로세스**
 1. 원하는 군집 수만큼 임의의 위치에 중심점을 설정합니다.
 2. 각 데이터는 가장 가까운 중심점에 소속.
 3. 소속이 결정되면 해당 데이터들의 평균 위치로 중심점을 이동합니다.
 4. 중심점이 이동했으므로 데이터를 가장 가까운 중심점으로 재소속시킴
 5. 더 이상 데이터의 소속 변경이 없을 때까지 이 과정을 반복하며 군집화를 완료합니다.
- **장점:** 알고리즘이 쉽고 간결하며, 가장 많이 활용됨
- **단점:** 거리 기반이므로 속성(피쳐)이 많을 때 정확도가 떨어지며(PCA 차원 감소 필요), 반복 횟수가 많으면 수행 시간이 느려짐. 또한, 처음부터 몇 개의 군집을 지정해야 할지 가이드하기 어려움

2. 사이킷런 KMeans 클래스 및 주요 파라미터

- **주요 파라미터:** 군집화할 개수를 뜻하는 `n_clusters`, 초기 중심점 좌표 설정 방식을 결정하는 `init`(주로 `k-means++` 방식 사용), 최대 반복 횟수인 `max_iter`
- **주요 속성:** 학습 후 `labels_`를 통해 각 데이터가 속한 군집 레이블을 확인하고, `cluster_centers_`를 통해 중심점 좌표를 얻어 시각화 가능
- **분석 예시 (붓꽃 및 가상 데이터):** * 붓꽃(Iris) 품종 데이터를 3개로 군집화했을 때 특정 품종은 명확히 잘 분리되지만, 일부 품종은 속성의 위치 자체가 겹쳐 명확히 분리되지 않는 한계가 관찰됨
 - 사이킷런은 군집화 테스트를 위해 `make_blobs()`(중심점 및 표준편차 제어 가능)와 `make_classification()`(노이즈 포함 가능) 등의 데이터 생성 API를 제공. 군집 데이터의 표준편차(`cluster_std`)가 작을수록 데이터가 중심에 모이고, 클수록 널리 퍼짐
 -

3. 군집 평가 (Cluster Evaluation) 및 실루엣 분석

- **평가의 한계:** 군집화는 분류와 달리 대부분 정답(타깃 레이블)이 없는 비지도학습이므로 정확하게 성능을 평가하기 어려움
- **실루엣 분석(Silhouette Analysis):** 군집 간의 거리가 얼마나 효율적으로 분리되어 있는지를 나타내는 대표적인 평가 방법. 효율적 분리란 다른 군집과는 거리가 멀고, 동일 군집끼리는 가깝게 뭉쳐 있음을 의미.
- **실루엣 계수:** 개별 데이터가 가지는 지표로, -1에서 1 사이의 값을 가짐. 1에 가까울수록 근처 군집과 멀리 떨어져 있음을 뜻하고, 0에 가까울수록 근처 군집과 가까워짐을, 음수(-) 값은 아예 다른 군집에 잘못 할당되었음을 의미.
- **좋은 군집화의 조건:**
 1. 전체 실루엣 계수의 평균값(0~1 사이)이 1에 가까울수록 좋음.
 2. 전체 평균이 높더라도 특정 군집만 유난히 높고 다른 군집은 낮으면 안되며, 개별 군집별 평균값의 편차가 작아야 함
- **단점:** 모든 데이터 간의 거리를 반복적으로 계산하므로 데이터양이 늘어나면(수만 건 이상) 수행 시간이 급증하고 메모리 부족 에러가 발생하기 쉬움 (샘플링 평가 필요).

4. 평균 이동(Mean Shift) 알고리즘 개요

- **정의:** K-평균과 유사하게 중심을 지속적으로 움직이며 군집화를 수행하는 기법
- **차이점:** K-평균이 데이터의 단순 '평균 거리 중심'으로 이동한다면, 평균 이동은 데이터가 모여 있는 '밀도가 가장 높은 곳'으로 중심을 이동시킴
- **원리:** 데이터의 분포도를 이용해 중심점을 찾기 위해 확률 밀도 함수(KDE: Kernel Density Estimation)를 사용하며, 확률 밀도 함수가 피크(Peak)인 점을 군집 중심점으로 선정하여 업데이트를 반복