

week10 예습과제

≡ 다중 선택

week11

Ch.7 군집화


06 군집화 실습 - 고객 세그먼테이션

01 K-평균 알고리즘 이해

K-평균

: 군집 중심점을 선택해 해당 중심에서 가장 가까운 포인트들을 선택하는 군집화 기법(비지도학습)

- 동작 과정



1. 군집화 개수 만큼 임의의 위치에 군집 중심점 배치
2. 데이터는 가장 가까운 곳에 위치한 군집 중심점의 소속으로 결정
3. 소속된 데이터의 평균 중심으로 군집 중심점 이동
4. 이동한 중심점을 기준으로 다시 데이터의 소속 결정
5. 중심점 이동 후 데이터의 중심점 소속 변경이 없을 때까지 반복

- 장점

- 가장 일반적이고 많이 활용됨
- 쉽고 간결한 알고리즘

- 개별 군집 내의 데이터가 원형으로 흩어져 있는 경우 매우 효과적
- 단점
 - 거리 기반 알고리즘 → 속성의 개수가 많을 경우 군집화 정확도 ↓
(⇒ 이 경우 PCA 활용 가능)
 - 반복 횟수 많을 경우 수행 시간이 매우 느려짐
 - 군집의 개수 선택 가이드가 어렵

사이킷런 KMeans 클래스

- 초기화 파라미터

```
class sklearn.cluster.KMeans(n_clusters=8, init='k-means++', n_init=10,
max_iter=300, tol=0.0001,
precompute_distances='auto',
verbose=0, random_state=None, copy_x=True,
n_jobs=1, algorithm='auto')
```

- 주요파라미터
 - `n_clusters` : 군집화 개수, 군집 중심점의 개수
 - `init`
 - 초기 군집 중심점 좌표 설정 방식
 - 보통 임의 설정 X고 `'k-means++'` 로 설정
 - `max_iter` : 최대 반복 횟수, 이 횟수 이전 중심점 이동 없으면 종료
- 수행 메서드
 - `fit(데이터세트)`
 - `fit_transform(데이터세트)`
- 주요 속성
 - `labels_` : 각 데이터 포인트가 속한 군집 중심점 레이블

- `cluster_centers_` : 각 군집 중심점 좌표, Shape : [군집 개수, 피쳐 개수]

군집화 알고리즘 테스트를 위한 데이터 생성

- 군집화 알고리즘 테스트를 위한 데이터 생성기

API	주목적	같은 라벨의 여러 군집 생성	
<code>make_blobs()</code>	군집화	기본적으로 X	개별 군집의 중심점과 표준 편차 제어 기능 추가
<code>make_classification()</code>	분류	O	노이즈를 포함한 데이터 생성에 유용
<code>make_circle()</code> , <code>make_moon()</code>			중심 기반의 군집화로 해결하기 어려운 데이터 세트 생성에 유용

- `make_blobs()`
 - 반환 : 피쳐 데이터 세트와 타깃 데이터 세트를 튜플로 반환
 - 호출 파라미터
 - `n_samples` : 생성할 총 데이터의 개수, default = 100
 - `n_features` : 데이터의 피쳐 개수
 - `centers`
 - int 값으로 설정 : 군집의 개수
 - ndarray 형태로 설정 : 개별 군집 중심점의 좌표
 - `cluster_std` : 생성될 군집 데이터의 표준 편차
 - 군집 별로 같은 표준 편차 사용 → float 값으로 지정
 - 군집 별로 서로 다른 표준 편차 사용 → 리스트로 지정


02 군집 평가

→ 군집화는 비지도학습의 특성상 어떠한 지표로 정확하게 성능 평가가 어렵

실루엣 분석의 개요

: 군집화 평가 방법, 각 군집 간의 거리가 얼마나 효율적으로 분리돼 있는지 나타냄

- 특징 및 정의
 - 개별 데이터가 가짐
 - 해당 데이터가 같은 군집 내의 데이터와 얼마나 가깝게 군집화돼 있고, 다른 군집에 있는 데이터와는 얼마나 멀리 분리돼 있는지 나타내는 지표
- 계산
 - a_{ij} , b_{ij} , $a(i)$, $b(i)$



- $s(i)$
 - 정의

$$s(i) = \frac{(b(i) - a(i))}{(\max(a(i), b(i)))}$$

- 특징
 - $-1 \leq s(i) \leq 1$
 - 1에 가까워질 수록 근처 군집과 더 멀리 떨어져 있다는 뜻
 - 0에 가까울 수록 근처 군집과 가까워진다는 뜻
 - - 값이면 아예 다른 군집에 데이터 포인트가 할당됐다는 뜻
- 장단점
 - 장점 : 직관적으로 이해하기 쉬움

- 단점 : 데이터별로 다른 데이터와의 거리를 반복적으로 계산 → 데이터 양이 많으면 수행시간 크게 늘

실루엣 분석을 위한 사이킷런의 메서드

- 메서드 종류


- `sklearn.metrics.silhouette_samples(X, labels, metric='euclidean', **kwargs)`
 - 인자 : X feature 데이터 세트와 각 피쳐 데이터 세트가 속한 군집 레이블 값인 labels 데이터를 입력
 - 반환 : 각 데이터 포인트의 실루엣 계수를 계수를 계산해 반환
- `sklearn.metrics.silhouette_score(X, labels, metric='euclidean', sample_size=None, **kwargs)`
 - 인자 : X feature 데이터 세트와 각 피쳐 데이터 세트가 속한 군집 레이블 값인 labels 데이터를 입력해
 - 반환 : 전체 데이터의 실루엣 계수 값을 평균해 반환 ⇒ `np.mean(silhouette_samples())`
 - 일반적으로 이 값이 높을수록 군집화가 어느 정도 잘 됐다고 판단 가

- 좋은 군집화의 기준


- 전체 실루엣 계수의 평균값(=사이킷런의 `silhouette_score( )` 값이 0 ~ 1 사이의 값
→ 1에 가까울수록 good
- 개별 군집의 평균값의 편차가 크지 않음
 - ex - 만약 전체 실루엣 계수의 평균값은 높지만, 특정 군집의 실루엣 계수 평균값만 유난히 높고 다른 군집들의 실루엣 계수 평균값은 낮으면 좋은 군집화 조건X

군집별 평균 실루엣 계수의 시각화를 통한 군집 개수 최적화 방법

- 개별 군집에 속하는 데이터의 실루엣 계수를 2차원으로 나타낸 도표 활용
 - ex
 - 3개로 나눈 경우 - 0번 군집의 모든 데이터는 평균 실루엣 계수보다 작음 → bad



- 4개로 나눈 경우 - 전체적으로 개별 군집의 평균 실루엣 계수 값이 균일하게 위치 → good




03 평균 이동

개요


- K-means와의 차이점 : 중심을 데이터가 모여있는 밀도가 가장 높은 곳으로 이동시킴 (↔ K-means : 소속된 데이터의 평균 거리 중심)
- 군집 중심점
 - 확률 밀도 함수 이용 → 확률 밀도 함수가 피크인 점(가장 집중저금로 데이터가 모여있는)을 선정
⇒ KDE(Kernal Density Estimation) 이용
- 동작 과정

: 개별 데이터들이 밀도가 높은 곳으로 이동 → 지정 횟수 만큼 반복 → 이동한 개별 데이터들이 모인 중심점을 군집 중심점으로 설정



• KDE


◦ 가우시안 커널 함수로 적용한 예시




◦ 함수식

$$KDE = \frac{1}{n} \sum_{i=1}^n K_h(x - x_i) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x - x_i}{h}\right)$$

- K : 커널 함수
- x : 확률 변수값(일반적인 함수의 x 값)
- x_i : 관측값(실제 데이터 값으로 상수)
- h : 대역폭(bandwidth)(개별 데이터에 적용하는 가우시안 커널 함수의 너비)
 - 너무 작은 h 값 적용한 KDE : 뾰족 / 과적합 쉬움 / 군집 중심점 많음



- 너무 큰 h 값 적용한 KDE : 부드러움 / 과소적합 쉬움 / 군집 중심점 적음




- 사이킷런의 `MeanShift` 클래스
 - 초기화 파라미터 `bandwidth` : 대역폭 h
 - 최적 대역폭 계산을 위한 `estimate_bandwidth()` 함수 사용 가능
- 장단점
 - 장점 : 유연한 군집화 가능 / 이상치의 영향력 크지 않음 / 군집 개수 정할 필요 X
 - 단점 : 수행시간이 오래 걸림 / band-width의 크기에 따른 군집화 영향도가 매우
- 활용
 - 분석 업무 기반의 데이터 세트보다는 **컴퓨터 비전 영역에서 많이 사용**
→ 이미지나 영상 데이터에서 특정 개체 구분 / 움직임 추적

04 GMM(Gaussian Mixture Model)

GMM 소개

: 군집화를 적용하고자 하는 데이터가 여러 개의 가우시안 분포를 가진 데이터 집합들이 섞여서 생성된 것이라는 가정하에 군집화를 수행하는 방식

- 모수 추정



- 데이터 세트를 구성하는 여러 개의 정규 분포 곡선 추출 → 개별 데이터가 이 중 어떤 정규 분포에 속하는지 결정
- EM 알고리즘 적용
- 사이킷런의 `GaussianMixture` 클래스
 - GMM의 EM 방식을 통한 모수 추정 군집화 지원
 - 중요한 초기화 파라미터 `n_components` : gaussian mixture의 모델의 총 개수 → 군집의 개수 결정에 영향 ↑


GMM과 K-평균의 비교

- K-means 군집화 : 원형의 범위로 데이터를 군집화 → 원형의 범위로 퍼져 있지 않은 경우 수행 어렵 ex) 타원 형
- GMM : K-means보다 유연하게 다양한 데이터 세트에 잘 적용될 수 있음 but 수행 시간이 오래 걸림

05 DBSCAN

: 밀도 기반 군집화의 대표적인 알고리즘

- 장점
 - 간단하고 직관적인 알고리즘
 - 데이터 분포가 기하학적으로 복잡한 데이터 세트에도 효과적인 군집화 가능
 - ex)



- 주요 파라미터
 - 입실론 주변 영역(epsilon) : 개별 데이터를 중심으로 입실론 반경을 가지는 원형의 영역
 - 최소 데이터 개수(min points) : 개별 데이터의 입실론 주변 영역에 포함되는 타 데이터의 개수
- 각 데이터 포인트 정의
 - 기준 : 입실론 주변 영역 내에 포함되는 최소 데이터 개수를 충족시키는가 아닌가
 - 핵심 포인트(Core Point): 주변 영역 내에 최소 데이터 개수 이상의 타 데이터를 가지고 있을 경우
 - 이웃 포인트(Neighbor Point) : 주변 영역 내에 위치한 타 데이터
 - 경계 포인트(Border Point) : 주변 영역 내에 최소 데이터 개수 이상의 이웃 포인트를 가지고 있지 않지만 핵심 포인트를 이웃 포인트로 가지고 있는 데이터
 - 잡음 포인트(Noise Point) : 최소 데이터 개수 이상의 이웃 포인트를 가지고 있지 않으며, 핵심 포인트도 이웃 포인트로 가지고 있지 않는 데이터
- 사이킷런의 **DBSCAN** 클래스
 - 초기화 파라미터
 - eps : 입실론 주변 영역의 반경
 - min_samples : 핵심 포인트가 되기 위해 입실론 주변 영역 내에 포함돼야 할 데이터의 최소 개수(자신의 데이터를 포함) .