

텍스트 분석

- 감성 분석(Sentiment Analysis)

- 감성 분석은 텍스트가 긍정인지 부정인지 감정을 판별하는 기법이다.
- SentiWordNet과 VADER 같은 감성 사전을 이용해 감정을 예측할 수 있다.
- 감성 사전 기반 방식은 지도학습보다 성능이 낮을 수 있으나, 정답 데이터가 없는 경우에도 활용 가능하다.
- VADER는 SentiWordNet보다 재현율이 높아 감정 표현을 더 효과적으로 탐지했다.
- 감성 분석은 리뷰 분석, 여론 분석, 고객 반응 파악 등에 활용된다.

- 토픽 모델링(Topic Modeling)

- 토픽 모델링은 문서 집합 속에 숨어 있는 핵심 주제를 자동으로 찾는 비지도학습 기법이다.
- 대표 기법으로 LSA와 LDA가 있으며, 자료에서는 LDA(Latent Dirichlet Allocation)를 사용했다.
- LDA는 차원 축소 기법인 Linear Discriminant Analysis와 이름만 같고 다른 알고리즘이다.
- 20 뉴스그룹 데이터에서 8개 주제를 추출하여 토픽 모델링을 수행하였다.
- 토픽별로 연관도가 높은 단어를 통해 문서의 핵심 주제를 해석한다.
- 의학, 기독교, 중동, 윈도우 관련 주제는 비교적 명확하게 추출되었으나 일부 주제는 불분명했다.
- 토픽 모델링 성능은 데이터 특성과 토픽 개수 설정에 영향을 받는다.

- 문서 군집화(Document Clustering)

- 문서 군집화는 비슷한 문서를 자동으로 묶는 비지도학습 기법이다.
- 텍스트 분류와 유사하지만, 사전에 정답 카테고리가 필요하지 않다는 차이가 있다.
- Opinion Review 데이터 세트를 사용해 호텔, 자동차, 전자제품 리뷰를 군집화하였다.
- 문서를 분석하기 위해 먼저 파일을 DataFrame으로 로드하고 텍스트를 정리하였다.
- 텍스트는 TF-IDF 방식으로 벡터화하여 수치 데이터로 변환하였다.

- TF-IDF 벡터화

- TF-IDF는 단어의 중요도를 계산해 문서를 벡터로 표현하는 방법이다.
- 단순 빈도(TF)뿐 아니라 전체 문서에서의 희귀성(IDF)을 함께 고려한다.
- 불용어 제거, 어근 추출, n-gram 설정 등을 통해 의미 있는 단어만 남긴다.
- TF-IDF는 문서 군집화와 문서 유사도 분석의 핵심 전처리 과정이다.

- K-Means 기반 문서 군집화 결과

- K-Means 알고리즘을 사용해 문서를 군집화하였다.
- 군집 수를 5개로 설정했을 때는 세부 주제별로 군집이 형성되었으나 다소 세분화되는 경향이 있었다.
- 군집 수를 3개로 줄이자 전자제품, 자동차, 호텔 리뷰라는 직관적인 그룹으로 정리되었다.
- 군집 수 설정은 결과 해석에 큰 영향을 미친다.

- 군집별 핵심 단어 추출

- K-Means의 cluster_center를 활용하면 군집을 대표하는 핵심 단어를 찾을 수 있다.
- 전자제품 군집: screen, battery, battery life 등 화면·배터리 관련 단어가 핵심이었다.
- 자동차 군집: interior, seat, mileage, comfortable 등 실내와 연비 관련 단어가 핵심이었다.
- 호텔 군집: room, service, staff, location 등이 주요 단어로 나타났다.
- 핵심 단어를 통해 군집이 어떤 주제를 중심으로 형성되었는지 해석할 수 있다.

- 문서 유사도(Document Similarity)

- 문서 유사도는 문서 간 얼마나 비슷한지를 수치로 표현하는 방법이다.
- 대표적인 방식은 코사인 유사도(Cosine Similarity)이다.
- 코사인 유사도는 벡터의 길이가 아니라 방향의 유사성을 측정한다.
- 텍스트 데이터는 희소 행렬 형태가 많기 때문에 코사인 유사도가 특히 효과적이다.
- 문서 길이가 달라도 단어 사용 패턴이 비슷하면 높은 유사도를 가진다.

- 코사인 유사도 활용

- 간단한 문장 예제에서 TF-IDF 벡터를 기반으로 코사인 유사도를 계산하였다.

- 사이킷런의 cosine_similarity() 함수를 사용하면 문서 간 유사도를 쉽게 계산할 수 있다.
- 개별 문서 비교뿐 아니라 전체 문서 쌍의 유사도 행렬도 생성 가능하다.
- Opinion Review 데이터에서 호텔 리뷰 간 유사도를 비교한 결과 실제로 비슷한 리뷰가 높은 유사도를 보였다.
- 문서 유사도는 추천 시스템, 검색 시스템, 유사 문서 탐색 등에 활용된다.

-한글 NLP의 어려움

- 한글 자연어 처리는 영어보다 복잡하다.
- 가장 큰 원인은 띄어쓰기와 조사 때문이다.
- 잘못된 띄어쓰기는 의미를 완전히 바꿀 수 있다.
- 조사는 종류가 다양하고 어근과 결합해 형태소 분석을 어렵게 만든다.
- 따라서 한글 NLP에서는 형태소 분석과 전처리가 매우 중요하다.

- KoNLPy 소개

- KoNLPy는 대표적인 파이썬 기반 한글 형태소 분석 패키지이다.
- 형태소 분석은 문장을 의미 단위로 분리하고 품사를 부착하는 과정이다.
- KoNLPy는 Kkma, Hannanum, Komoran, Mecab 등 다양한 엔진을 지원한다.
- Mecab은 성능이 우수하지만 윈도우에서는 사용이 제한된다.
- KoNLPy 사용을 위해 Java와 JPyype 환경 설정이 필요하다.

-전체 흐름 정리

- 텍스트 분석은 일반적으로 다음 순서로 진행된다.
- ① 텍스트 전처리 → ② 벡터화(TF-IDF) → ③ 토픽 모델링·군집화·유사도 분석 → ④ 결과 해석
- 머신러닝 기반 텍스트 분석은 대량 문서에서 주제 추출, 문서 분류, 의미 비교를 효율적으로 수행할 수 있다.